## 《人工智能》实验报告

学号: SA18225034

姓名: 陈建虎

班级: 18级大数据2班

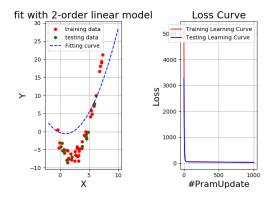
- 一、对于给定的模型,比如二阶模型 y=w1\*x2 + w2\*x + b, 尝试找出该 model 中的最佳 function。
- 1. 验证数据归一化技术的效果。采用 BGD。

超参数设置如下:

training_epochs	Learning	N	TestingDataRatio	OrderNum Seed		BatchSize
	Rate					
int (1000)	1*1e-4	50	0.2	2	16225151	N*(1-TestingDataRatio)

## a) 设置 DataScaleFlag=0 时:

### 运行结果:

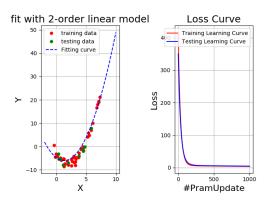


tensorboard: (train set)



# b) 设置 DataScaleFlag=1 时:

### 运行结果:



#### tensorboard: (train\_set)



### <u>总结:</u>

通过观察上面的实验结果,明显能感觉到使用了数据归一化技术时 Total\_cost 的收敛速

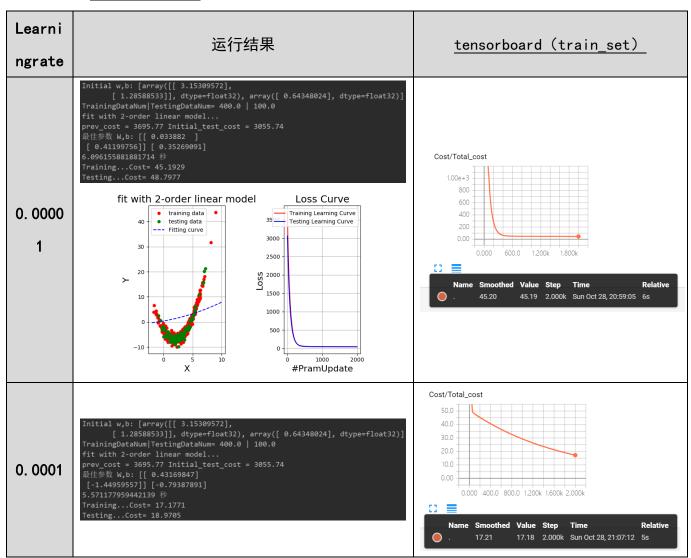
度明显比没有使用此技术时快。大约在<u>第 300 轮</u>左右时,使用<u>数据归一化技术</u>的模型 Total\_cost **基本收敛,**而未使用此技术的模型到最后(epochs=1000)也没能收敛。

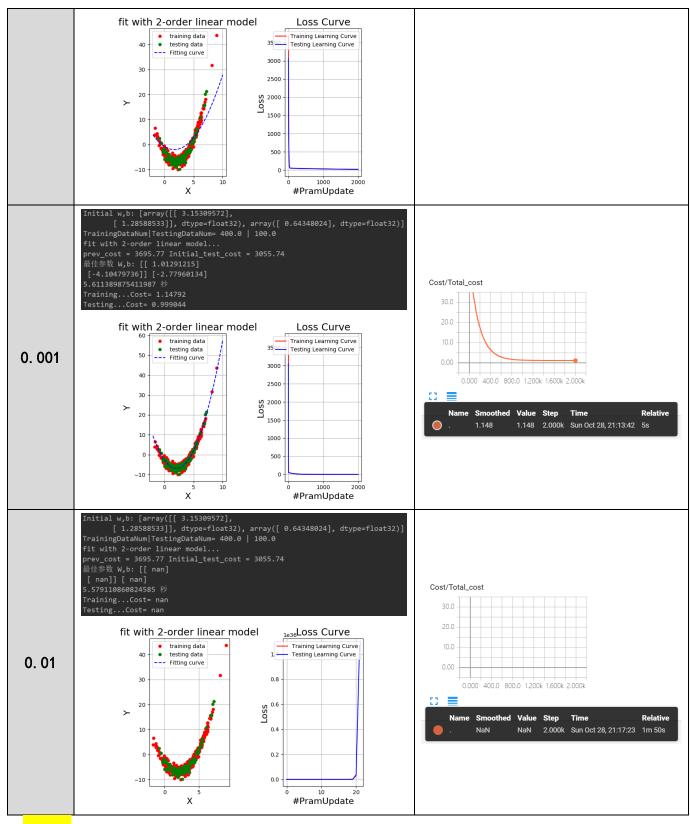
### 2. 学习率对收敛速度的影响。

### 2.1) 采用 BGD。超参数设置如下:

training_epochs	BatchSize	N	TestingDataRatio	OrderNum	Seed	DataScaleFlag
int (2000)	N*(1-TestingDataRatio)	500	0. 2	2	16225151	0

不同 learning rate 运行结果如下





## <u>总结:</u>

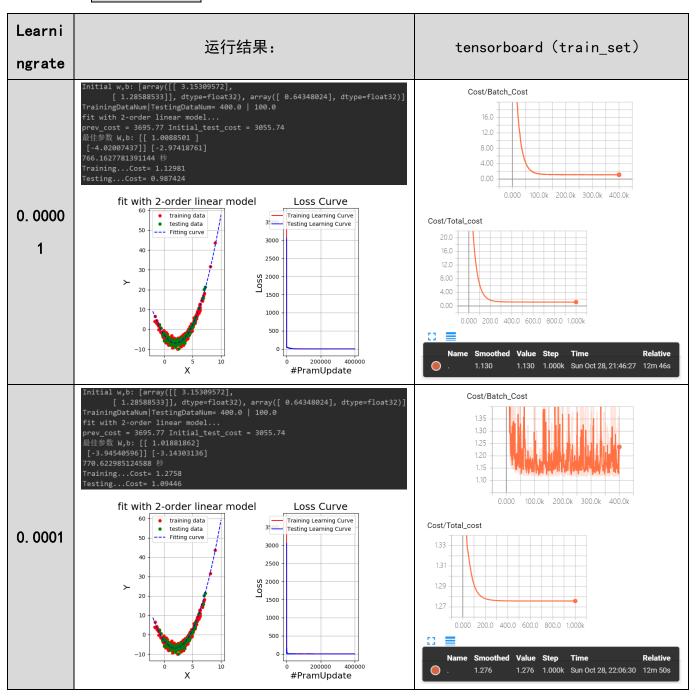
通过观察上面的实验结果发现,当 1r 太小时(1\*1e-5),  $Total\_cost$  收敛得极慢,2000 轮训练完成时 cost 依然很高,这时应该适当增大 1r (从 1\*1e-5 到 1\*1e-4 再到 1\*1e-3),适

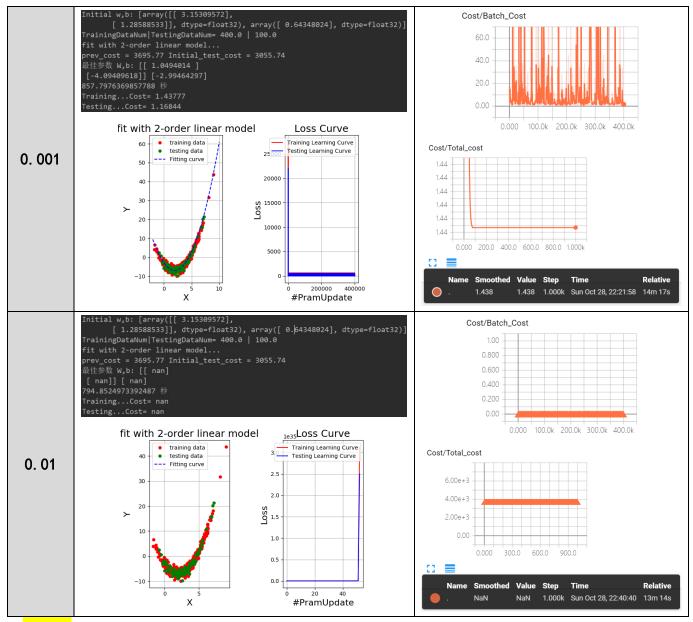
当增大后发现 Total\_cost 收敛速度增加,当 1r=0.001 时,cost 最小,同时收敛速度也最快。 当尝试再增大 1r 到 0.01 时,发现 cost 直接跨过最小值,朝着无限大的方向去了。出现此原 因就是 1r 太大,即更新参数的步长太大。

# 2.2) 采用 SGD。超参数设置如下:

training_epochs	BatchSize	N	TestingDataRatio	OrderNum	Seed	DataScaleFlag
int (1000)	1	500	0.2	2	16225151	0

不同 learning rate 运行结果如下





### 总结:

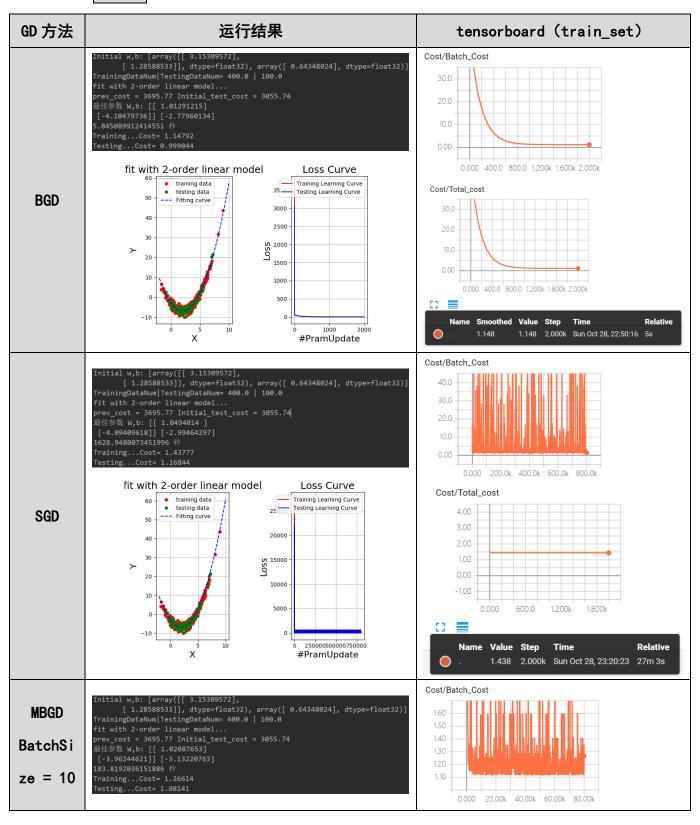
通过观察上面的实验结果发现,当使用随机梯度下降算法时,1r 对 Total\_cost 收敛速度 影响与使用 BGD 时基本一致,即随着 1r 的逐步增大,Total\_cost 收敛速度越来越快,但当超过某一阈值(0.01)时,情况会变得非常糟。

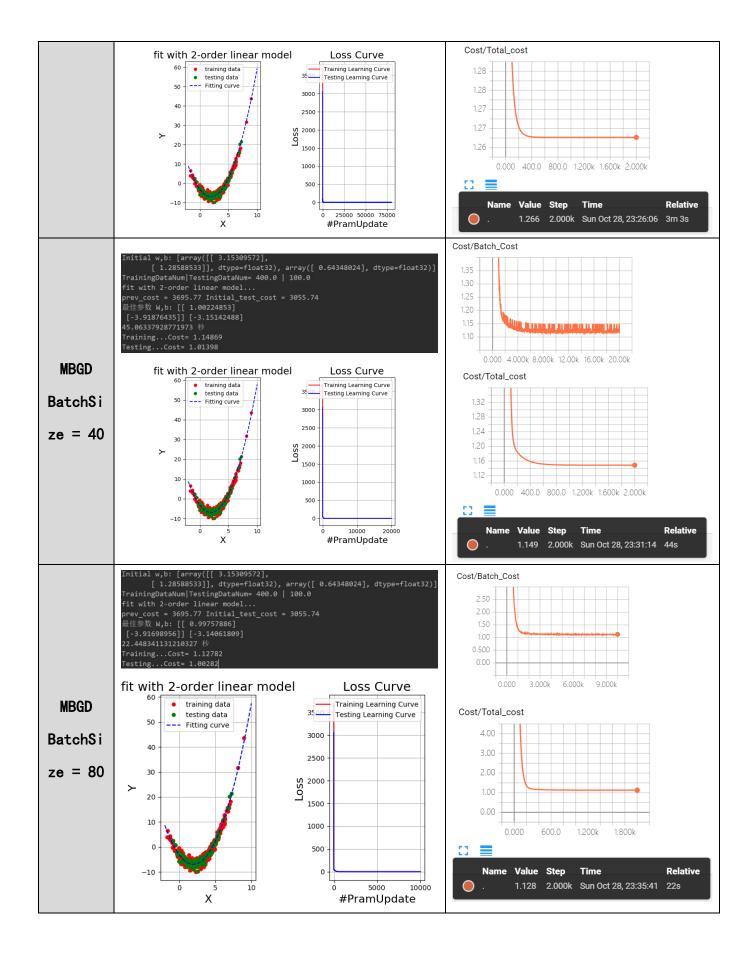
除此之外,还能观察到 Batch\_cost 会出现大幅抖动的情况,主要原因就是随机梯度下降 算法每次更新参数时,只使用一个实例。

3. 对比 BGD, SGD 和 MBGD, 并进一步观察分析 MBGD 中 BatchSize 对收敛稳定性和收敛速度的影响。使用基本的 GD 方法, 超参数设置如下:

training_epochs	Learning Rate	N	TestingDataRatio	OrderNum	Seed	DataScaleFlag
int (2000)	1*1e-3	500	0.2	2	16225151	0

## 不同GD方法运行结果如下





通过观察发现如下现象:

- 1) Batchsize=80时, Total Loss 收敛最快。
- 2) BGD下, Total Loss 稳定的下降,不断朝极小值接近,但收敛速度慢。
- 3) SGD 和 Batchsize=10 这两种情况下,很早就出现了 Total Loss 值不再下降的现象,但实际上此时并没有找到 Total Loss 的极小值。
- 4) MBGD下,随着 Batchsize 的取值不同,Batch Cost 出现了不同程度的震荡。

## 问题

#### Q1: 现象 3) 中,为何会出现 Total Loss 值不再更新的现象呢?

答: 因为当 SGD 和 Batchsize=10 这两种情况时,参数更新太为频繁,很可能会找到最值后因为某些噪声实例,导致 Total cost 又跳出最小值。

#### Q2: 现象 4) 中,为何会出现震荡?

答: 当 batchsize=1 时,MBGD 变为 SGD,此时更新一次参数只随机从训练集中抽取一个实例,所以 Batch\_Cost 抖动程度最大; 当 batchsize=10 时,通过 10 个实例的 loss 求平均的方法来更新参数,此时会比 batchsize=1 稍微稳定一点点,但是还是存在较大抖动,以此类推,当 batchsize 逐渐增大到 40 和 80 时,Batch\_Cost 抖动越来越小,但 batchsize 过大时也不好,因为这样会导致更新参数的速度了变得很慢,即导致 cost 收敛很慢。

#### Q3: 你觉得以上 5 种不同的 BatchSize 中,哪种取值最好? 为什么?

答: 我会选择 BatchSize=40。因为此时 Batch\_Cost 震荡幅度不会太大,Total\_cost 的收敛速度也比较可观,即能较好地平衡 Batch Cost 抖动和 Total cost 的收敛速度。

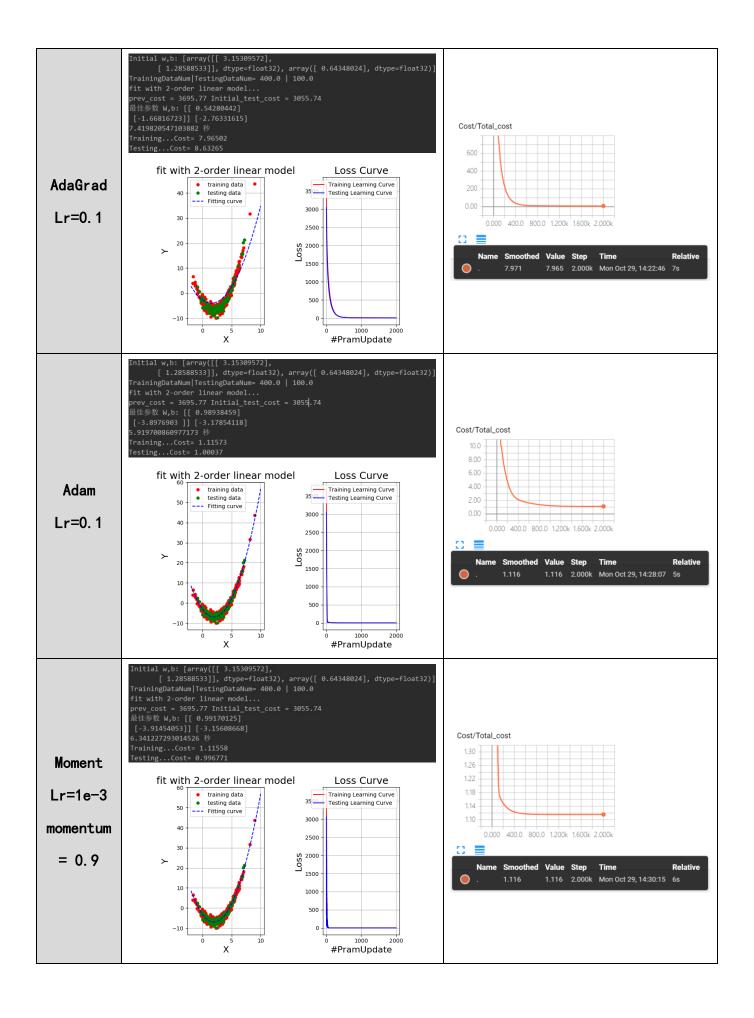
### 4. 验证常用梯度优化算法的效果。

超参数设置如下:

training_epochs	Learning Rate	BatchSize	N	TestingDataRatio	OrderNum	Seed	DataScaleFlag
int(2000)	1e-3	N*(1-TestingDataRatio)	500	0.2	2	16225151	0

## 不同优化方法运行结果如下

优化方法	运行结果:	tensorboard (train_set)
------	-------	-------------------------



### Q: 通过观察分析, 你认为, 对于当前代码, 哪种梯度优化算法最好? 为什么?

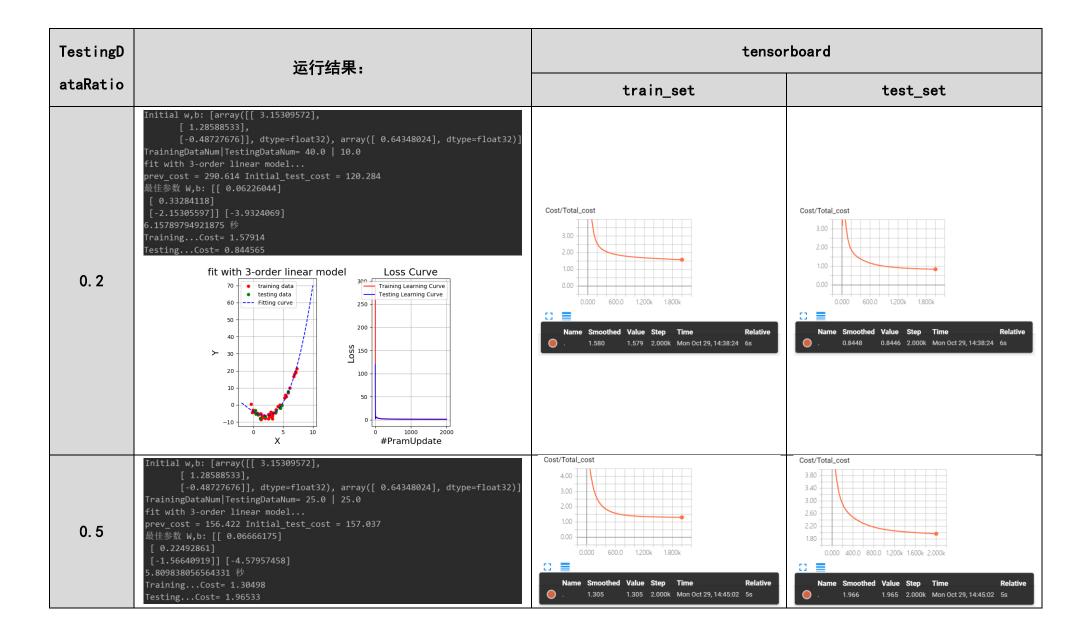
答:我 Moment 算法最好。因为在使用 Moment 算法时,Total\_cost 的收敛速度最快,它引入了物理学中动量因素,从而可以使得参数在梯度非常大的地方更新的非常快,并且也能使 loss 避免陷入局部最小值和鞍点,更容易到达全局最小值

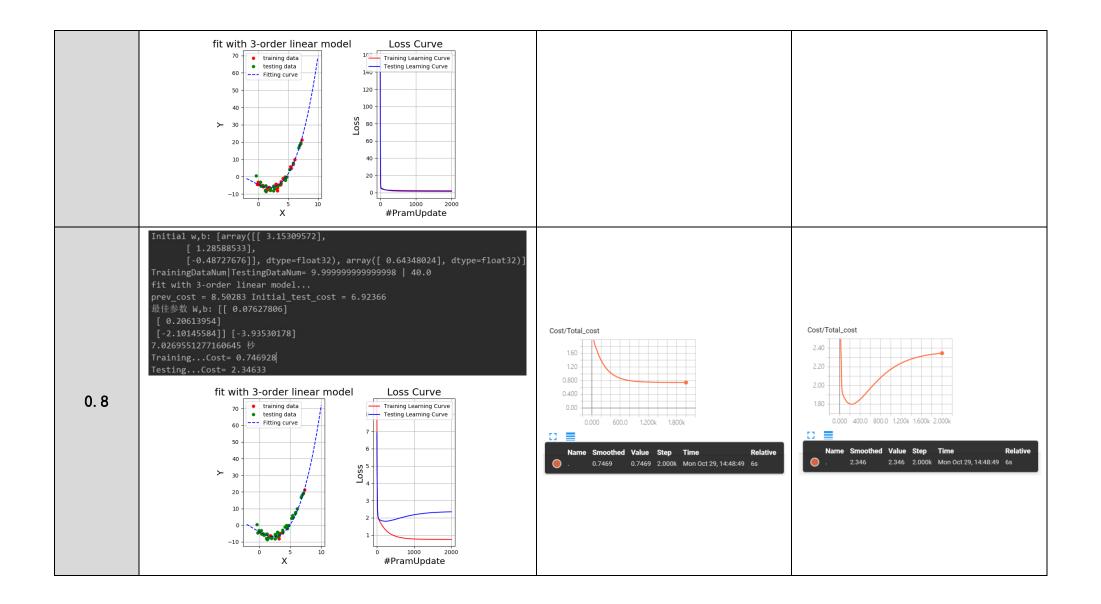
5. 数据集和验证集 CV 划分对"过拟合"的影响。采用 BGD 作为梯度下降方法。超参数设置如下:

training_epochs	Learning Rate	BatchSize	N	OrderNum	Seed	DataScaleFlag
int (2000)	0.001	N*(1-TestingDataRatio)	50	3	16225151	1

优化器选择: GradientDescentOptimizer

不同 TestingDataRatio 运行结果如下:





### 总结

过拟合的情况: TestingDataRatio=0.8

**训练数据集的数据量对过拟合的影响:**通过实验观察可知:训练集数量越少,越容易产生过拟合。

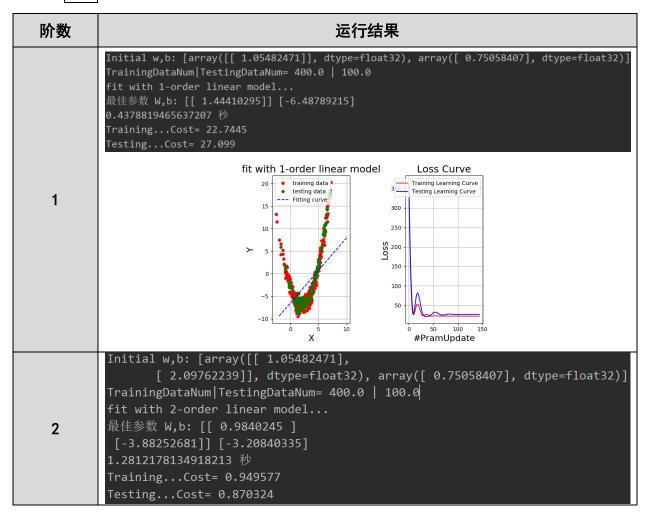
#### 二、跨越不同模型进行比较,从而找出终极的最佳 function。

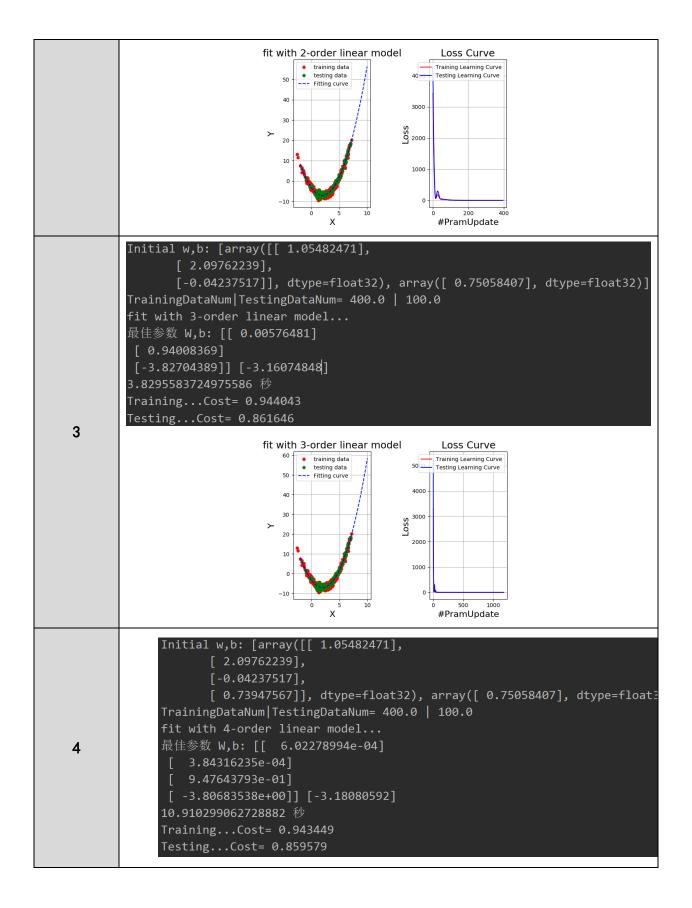
超参数设置如下:

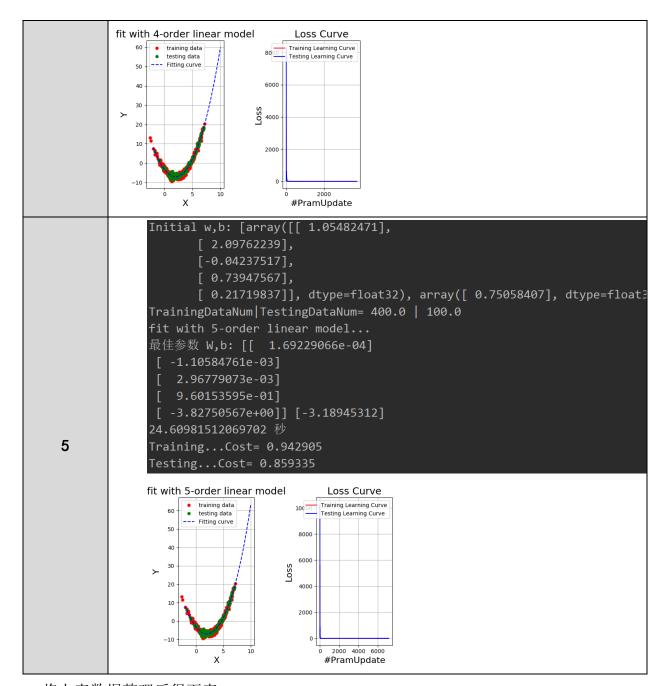
training_epochs	BatchSize	N	TestingDataRatio	Learning Rate	Seed	DataScaleFlag
int(1e20)	N*(1-TestingDataRatio)	500	0. 2	0. 1	18225034	1

优化器: Adam

不同<mark>阶数</mark>运行结果如下: seed=18225034







将上表数据整理后得下表:

Model & Optimized function	Training Loss	Testing Loss	
1 阶: y=1.44x-6.49	22. 7445	27. 099	
2 阶: y=0.98*x²-3.88*x-3.21	0. 949577	0.870324	
3 阶: y=5.8e-3*x³+0.94x²-3.82*x-3.16	0. 944043	0.861646	
4 阶: y=6.02e-4*x <sup>4</sup> +3.84e-4*x <sup>3</sup> +0.95x <sup>2</sup> -3.80*x-3.18	0. 943449	0. 859579	
5 阶:	0. 942905	0.859335	
y=1.69e-4*x5-1.11e-3*x4+2.97e-3*x3+0.96x2-3.82*x-3.19			

Q: 观察上表中你的记录结果, 试找出跨模型的最佳 function, 并说出你的选择理由。 答: 最佳模型为 2 阶: y=0.98\*x²-3.88\*x-3.21。

原因如下:第一,虽然在增加阶数到 3/4/5 时,看不出明显的过拟合,但是可以明显发现,阶数升高时,最终训练结果中,3次及3次以上的项参数都几乎接近于0,所以相当于还是2阶模型。第二,如果我们选择高阶模型,有可能会增加过拟合的几率。